

```

In [18]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

df = pd.read_csv('ID_data_mass_18122012.xlsx - VU.csv', sep = ',', decimal = ')
df = df.iloc[1:].reset_index(drop=True)

for col in df.columns:
    if col not in ['№', 'дд.мм.гггг']:
        df[col] = df[col].astype(str).str.replace(',', '.').astype(float, errors='ignore')

df['КГФ_общий'] = df['КГФ'].copy()

mask = df['КГФ_общий'].isna() & df['КГФ.1'].notna()
df.loc[mask, 'КГФ_общий'] = df.loc[mask, 'КГФ.1'] * 1000

df = df.drop(columns=['КГФ', 'КГФ.1'])

rows_drop = df[df['G_total'].isna() & df['КГФ_общий'].isna()].index
df.drop(index = rows_drop, inplace = True)

print(f"Удалены строки с двумя пустыми целевыми переменными: {len(rows_drop)}")

```

Удалены строки с двумя пустыми целевыми переменными: 92

```

In [19]: not_feature = ['G_total', 'КГФ_общий', 'Unnamed: 0', 'Unnamed: 1']
features = [col for col in df.columns
             if col not in not_feature
             and df[col].notna().sum() > 5]
print(f"Признаки: {features}")

```

Признаки: ['Глубина манометра', 'Дшт', 'Руст', 'Рзаб', 'Рлин', 'Руст.1', 'Рзаб.1', 'Рлин', 'Туст', 'Тна шлейфе', 'Тзаб', 'Тлин', 'Дебит газа', 'Дебит ст. ко нд.', 'Дебит воды', 'Дебит смеси', 'Дебит гааз', 'Дебит кон нестабильный', 'Дебит воды.1', 'Нэф', 'Рпл. Тек (послед точка на КВД)', 'Рпл. Тек (Расчет по КВД)', 'Рпл. Тек (Карноухов)', 'Рсб', 'Рсб.1', 'Ro_g', 'Ro_c', 'Ro_w', 'Удельная плотность газа ']

```

In [20]: from math import log2
def calculate_gain_ratio(data, feature, target):
    clean_data = data[[feature, target]].dropna()

    if len(clean_data) == 0:
        return 0

    feature_vals = clean_data[feature]
    target_vals = clean_data[target]

```

```

try:
    target_discrete = pd.qcut(target_vals, q=4, labels=False, duplicates='
except:
    return 0

def entropy(series):
    if len(series) == 0:
        return 0
    probs = series.value_counts(normalize=True)
    return -sum(p * log2(p) if p > 0 else 0 for p in probs)

total_entropy = entropy(target_discrete)

weighted_entropy_after = 0
split_info = 0

for value in feature_vals.unique():
    subset_idx = feature_vals[feature_vals == value].index
    subset_target = target_discrete[subset_idx]
    weight = len(subset_target) / len(target_discrete)
    weighted_entropy_after += weight * entropy(subset_target)
    split_info += -weight * log2(weight) if weight > 0 else 0

info_gain = total_entropy - weighted_entropy_after

if split_info == 0:
    return 0
gain_ratio = info_gain / split_info
return gain_ratio

```

In [21]: gain_ratio_scores = {}


```

for feature in features:
    gr_g = calculate_gain_ratio(df, feature, 'G_total')
    gr_kgf = calculate_gain_ratio(df, feature, 'КГФ_общий')
    gain_ratio_scores[feature] = np.nanmean([gr_g, gr_kgf])

sorted_features = sorted(gain_ratio_scores.items(), key=lambda x: x[1], reverse=True)
features_sorted = [x[0] for x in sorted_features]
scores_sorted = [x[1] for x in sorted_features]

plt.figure(figsize=(12, 8))
plt.barh(features_sorted, scores_sorted)
plt.xlabel('Gain Ratio')
plt.title('Важность признаков')
plt.gca().invert_yaxis()
plt.grid(axis='x', linestyle='--', alpha=0.7)
plt.tight_layout()
plt.show()

```




```
In [22]: df_corr = df[features + ['G_total', 'КГФ_общий']].copy()

df_corr_clean = df_corr.dropna()

corr_matrix = df_corr_clean.corr().abs()

plt.figure(figsize=(16, 14))
sns.heatmap(corr_matrix,
            annot=True,
            fmt='.2f',
            cmap='Reds',
            square=True,
            linewidths=0.5,
            cbar_kws={'label': 'Коэффициент корреляции по модулю'})
plt.title('Матрица корреляций признаков по модулю')
plt.tight_layout()
plt.show()

print("Топ-5 признаков по корреляции с G_total:")
print(corr_matrix['G_total'].sort_values(ascending=False).head(6))
print("\nТоп-5 признаков по корреляции с КГФ:")
print(corr_matrix['КГФ_общий'].sort_values(ascending=False).head(6))
```



Топ-5 признаков по корреляции с G_total:

```
G_total      1.000000
Дебит смеси  0.996460
Дебит газа   0.994137
Дебит ст. конд. 0.973012
Дебит воды   0.931734
Дебит воды.1 0.902640
Name: G_total, dtype: float64
```

Топ-5 признаков по корреляции с КГФ:

```
КГФ_общий    1.000000
Рзаб.1        0.664221
Рзаб          0.655161
Руст          0.649257
Дебит кон нестабильный 0.645170
Руст.1        0.619143
Name: КГФ_общий, dtype: float64
```

```
In [24]: print("\n Статистика и распределения признаков")
descriptive_stats = {}
```

```

for feature in features:
    df[feature] = pd.to_numeric(df[feature], errors='coerce')

print("Все признаки преобразованы в числа")
for feature in features:
    feature_data = df[feature].dropna()

    if len(feature_data) == 0:
        continue
    stats = {
        'count': len(feature_data),
        'mean': np.mean(feature_data),
        'std': np.std(feature_data),
        'min': np.min(feature_data),
        'q1': np.percentile(feature_data, 25),
        'median': np.median(feature_data),
        'q3': np.percentile(feature_data, 75),
        'max': np.max(feature_data)
    }
    descriptive_stats[feature] = stats

    plt.figure(figsize=(10, 4))
    plt.hist(feature_data, bins=30, edgecolor='black', alpha=0.7, density=True)
    plt.axvline(stats['q1'], color='red', linestyle='--', linewidth=2, label=f'Q1')
    plt.axvline(stats['median'], color='green', linestyle='--', linewidth=2, label=f'Median')
    plt.axvline(stats['q3'], color='blue', linestyle='--', linewidth=2, label=f'Q3')
    plt.xlabel(feature)
    plt.ylabel('Плотность')
    plt.title(f'Распределение признака: {feature}')
    plt.legend()
    plt.grid(axis='y', linestyle='--', alpha=0.7)
    plt.tight_layout()
    plt.show()

stats_df = pd.DataFrame(descriptive_stats).T
print("\nТаблица описательной статистики:")
print(stats_df.round(2))

print("\nОбработка выбросов и пропусков")

df_filled = df[features + ['G_total', 'КГФ_общий']].copy()
for col in df_filled.columns:
    median_val = df_filled[col].median()
    df_filled[col].fillna(median_val, inplace=True)

print("Пропуски заполнены медианными значениями.")

outlier_counts = {}
for col in features:
    Q1 = df_filled[col].quantile(0.25)
    Q3 = df_filled[col].quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR

```

```

upper_bound = Q3 + 1.5 * IQR

outliers = df_filled[(df_filled[col] < lower_bound) | (df_filled[col] > upper_bound)]
outlier_counts[col] = len(outliers)



df_filled[col] = np.where(df_filled[col] < lower_bound, lower_bound, df_filled[col])
df_filled[col] = np.where(df_filled[col] > upper_bound, upper_bound, df_filled[col])




outlier_df = pd.DataFrame.from_dict(outlier_counts, orient='index', columns=['feature'])
print("\nКоличество выбросов по признакам (до обработки):")
print(outlier_df[outlier_df['outlier_count'] > 0].sort_values(by='outlier_count', ascending=False))




print("\nВыбросы заменены на границы Q1-1.5IQR / Q3+1.5IQR.")




```




Статистика и распределения признаков
Все признаки преобразованы в числа




































Таблица описательной статистики:

	count	mean	std	min	q1 \
Глубина манометра	90.0	3524.09	143.67	3276.00	3427.62
Дшт	93.0	10.95	2.41	6.35	9.53
Руст	93.0	228.29	41.67	138.16	201.64
Рзаб	90.0	331.76	56.17	174.00	297.80
Рлин	93.0	99.86	7.26	73.31	95.95
Руст.1	93.0	227.64	41.53	136.00	200.00
Рзаб.1	90.0	330.33	56.04	174.00	294.62
Рлин	93.0	98.01	12.36	40.74	95.34
Туст	93.0	56.17	11.19	24.20	50.30
Тна шлейфе	60.0	43.09	19.44	14.00	33.30
Тзаб	90.0	104.96	1.24	100.21	104.52
Тлин	93.0	39.80	8.89	16.20	33.69
Дебит газа	93.0	394.40	149.54	128.37	287.95
Дебит ст. конд.	93.0	99.91	48.88	33.63	69.90
Дебит воды	93.0	2.13	1.87	0.00	0.70
Дебит смеси	89.0	417.02	156.86	136.82	306.24
Дебит гааз	93.0	3282.97	1345.75	884.00	2223.00
Дебит кон нестабильный	93.0	164.15	84.77	59.80	116.80
Дебит воды.1	93.0	2.16	1.89	0.00	0.70
Нэф	93.0	52.70	12.08	30.00	44.20
Рпл. Тек (послед точка на КВД)	88.0	40.68	5.34	29.17	37.21
Рпл. Тек (Расчет по КВД)	81.0	50.94	4.35	39.90	48.30
Рпл. Тек (Карноухов)	64.0	50.77	3.98	41.60	49.42
Рсб	93.0	95.16	5.11	85.50	90.70
Рсб.1	93.0	93.92	5.04	84.38	89.51
Ro_g	23.0	0.81	0.01	0.79	0.79
Ro_c	93.0	780.85	62.46	186.00	782.00
Ro_w	23.0	1000.00	0.00	1000.00	1000.00
Удельная плотность газа	93.0	0.67	0.02	0.57	0.66

	median	q3	max
Глубина манометра	3579.00	3652.25	3670.00
Дшт	11.11	12.70	15.88
Руст	229.89	252.00	337.11
Рзаб	337.79	364.15	458.60
Рлин	100.80	103.87	121.68
Руст.1	228.00	252.00	333.00
Рзаб.1	334.25	362.15	458.50
Рлин	100.26	104.00	123.62
Туст	58.00	64.00	75.00
Тна шлейфе	38.70	46.38	110.20
Тзаб	105.11	105.57	107.07
Тлин	40.52	47.80	55.51
Дебит газа	383.72	489.67	846.82
Дебит ст. конд.	89.80	117.60	302.62
Дебит воды	1.40	3.20	8.34
Дебит смеси	401.39	509.05	896.91
Дебит гааз	3112.00	4165.00	6943.10
Дебит кон нестабильный	143.50	185.20	492.80
Дебит воды.1	1.40	3.30	8.10
Нэф	56.80	63.50	72.54
Рпл. Тек (послед точка на КВД)	39.47	42.86	53.27

Рпл. Тек (Расчет по КВД)	50.80	55.40	56.70
Рпл. Тек (Карноухов)	50.90	52.70	56.80
Рсб	94.20	99.80	104.00
Рсб.1	92.97	98.49	102.64
Ro_g	0.81	0.82	0.82
Ro_c	787.00	793.70	801.00
Ro_w	1000.00	1000.00	1000.00
Удельная плотность газа	0.67	0.68	0.68

Обработка выбросов и пропусков
Пропуски заполнены медианными значениями.

Количество выбросов по признакам (до обработки):

	outlier_count
Рлин	8
Тзаб	8
Рпл. Тек (послед точка на КВД)	7
Дебит кон нестабильный	6
Тна шлейфе	5
Рлин	5
Рпл. Тек (Карноухов)	5
Дебит ст. конд.	4
Туст	3
Удельная плотность газа	3
Руст	1
Рзаб	1
Дебит газа	1
Рзаб.1	1
Руст.1	1
Дебит воды.1	1
Дебит смеси	1
Дебит воды	1
Ro_c	1

Выбросы заменены на границы $Q1-1.5IQR$ / $Q3+1.5IQR$.